

#05 · 語音對話 MVP

[修復+新增] 技術代號 VA-P0-1~4 · 約 3-5 天

一句話：語音對話按了沒反應

為什麼要修

麥克風按鈕、後台 WebSocket 通道、25 位精靈中的「聲聲」12
個工具都已存在，但完全沒接起來。

現在怎樣

前端 useOrbVoice.ts 是 WebSocket UI 骨架，無 getUserMedia / MediaRecorder。後端 orbVoiceGateway 收到音訊只回 '(stub) 收到語音資料'。STT/TTS 是 batch 模式未 streaming。

問題在哪

按麥克風純粹是裝飾，使用者無法真的用語音創作。

要改什麼

四件事接通：(1) 前端 MediaRecorder + Push-to-talk，(2) 後端 Gateway 接通 batch Whisper，(3) ElevenLabs streaming TTS，(4) voice-only MVP demo 工作流（說 → STT → multi-agent router → 結果 → TTS 朗讀）。

涉及檔案

client/src/hooks/useVoicePermissions.ts (新增)
client/src/hooks/useVoiceRecorder.ts (新增)
client/src/hooks/useOrbVoice.ts (既有改)
client/src/hooks/useAudioPlayback.ts (新增)
client/src/components/orb/OrbVoiceButton.tsx (既有改)
client/src/pages/VoiceAgentPage.tsx (新增)
shared/voice-protocol.ts (新增訊息協定 v2)
server/ws/orbVoiceGateway.ts (改寫 stub 為真實處理)
server/voice/voiceAgentSession.ts (新增)
server/voice/voiceStreamingTts.ts (新增)
server/voice/voiceAgentOrchestrator.ts (新增)

Claude Code 提示詞 (複製貼上)

把下面這段話完整複製，貼到 Claude Code (或 /claude 對話)。Claude Code 會依此完成此項修復。完成後跑下方驗證步驟確認。

請依照計畫附錄 E.1 ~ E.5 實作 VA-PO 語音對話 MVP：

前置：建議先完成第 2、3 條 (多代理路由與持久化)，因為語音任務會走 `runOrbTaskWithOptionalMultiAgent`。

【第 1 部分：訊息協定 v2】

1. 新增 `shared/voice-protocol.ts`，匯出 `VoiceClientMessage / VoiceServerMessage` union types。11 種 server message：ready、user-transcript-partial、user-transcript-final、agent-thinking、agent-text-chunk、agent-tool-call、agent-tool-result、audio-chunk、audio-end、error、session-stats。

【第 2 部分：前端錄音】

2. 新增 `client/src/hooks/useVoicePermissions.ts`，匯出 `useVoicePermissions()` 回傳 { status, ensure }。ensure() 呼叫 `navigator.mediaDevices.getUserMedia({ audio: { echoCancellation:true, noiseSuppression:true, autoGainControl:true, sampleRate:16000 } })`，測試完 `stop tracks`。

3. 新增 `client/src/hooks/useVoiceRecorder.ts`，匯出 `useVoiceRecorder({ onChunk, onStop, mode: "stream" | "push-to-talk" })`。內部用 `MediaRecorder + audio/webm;codecs=opus`，串流模式 250ms timeslice、push-to-talk 模式累積到 stop。

4. 新增 `client/src/hooks/useAudioPlayback.ts`，匯出 `useAudioPlayback()` 回傳 { enqueue, cancel }。內部用 `AudioContext + decodeAudioData`，順序播放 audio chunk。cancel() 清空 queue + suspend context。

5. 修改 `client/src/hooks/useOrbVoice.ts`：整合上述三個 hook，加 `pushToTalk: { start, stop }` API。WebSocket 收到 audio-chunk 用 enqueue 播放、收到 user-transcript-final 更新 UI、收到 error 顯示 toast。

6. 修改 `client/src/components/orb/OrbVoiceButton.tsx` 加 push-to-talk 模式：onMouseDown/onTouchStart 呼 start()、onMouseUp/onTouchEnd 呼 stop()。

【第 3 部分：後端接通 STT】

7. 修改 `server/ws/orbVoiceGateway.ts`，把 message handler 從 stub 換成呼叫新建的 `VoiceAgentSession`：binary chunks → `session.handleAudioChunk()`、JSON 訊息 → `session.handleClientMessage()`。

8. 新增 `server/voice/voiceAgentSession.ts`，class `VoiceAgentSession` 維護 chunks: `Buffer[]`、`handleClientMessage(msg)` 處理 start-utterance/end-utterance/interrupt、`handleAudioChunk(chunk)` 累積、`transcribeAndDispatch()` 用

Buffer.concat + internalMedia.storagePutBuffer 上傳暫存 (key prefix voice-tmp/) , 呼叫 transcribeAudio() 取 transcript , 呼叫 voiceAgentOrchestrator.dispatch()。

【第 4 部分：streaming TTS】

9. 新增 server/voice/voiceStreamingTts.ts , 匯出 streamTts({ text, voiceId, modelId, onChunk, onEnd, signal })。內部呼叫既有 elevenLabsExtended.textToSpeechStream , 預設 eleven_flash_v2_5 模型 , mp3_44100_128 格式 , for await chunk push 給 onChunk。

【第 5 部分：MVP 工作流】

10. 新增 server/voice/voiceAgentOrchestrator.ts , 匯出 dispatch({ session, transcript, lang })。流程：session.send agent-thinking → 呼叫 runOrbTaskWithOptionalMultiAgent (既有的多代理路由) → 把結果 summarizeOutcomeForVoice 壓成 < 80 字短句 → session.respondWithVoice 用 streamTts 朗讀 → 若有 assetUrl 送 agent-tool-result event。

11. 新增

client/src/pages/VoiceAgentPage.tsx : 中央大麥克風按鈕、上方對話歷史、下方生成結果預覽。預設 push-to-talk。收到 agent-tool-result 顯示縮圖。

【測試】

12. demo 腳本：使用者按住麥「幫我生成森林晨霧的圖」→ 應在 5 秒內看到 transcript → 圖生成 → TTS 朗讀「已完成」+ 圖出現。

不要做的事：不要做 streaming STT (Whisper 用 batch 即可，屬於進階)。不要做 barge-in / VAD (屬第 26 條進階版)。不要做 wake word。不要實作 Gemini Live API。

如何驗證做完了

前端按住麥克風說「你好」放開 → 1-2 秒內收到 user-transcript-final → AI 回應後 ElevenLabs streaming TTS 開始播放 (chunk 連續播放、不是等完整檔下載完)。完整 demo 腳本 (語音生圖) 跑通。

預估耗時

3-5 天