

#06 · LLM 快取

[修復] 技術代號 A-P0-4 / G-P0-2 · 約 1-2 天

一句話：同問題重複付費

為什麼要修

AI 服務的快取系統已寫好，但很多呼叫端忘了打開「使用快取」這個選項。

現在怎樣

server/_core/cache.ts CacheService 完整；server/_core/llm.ts:invokeLLM 已支援 cacheable / cacheTtlSeconds 參數。但 planner / critic / replan 入口都沒傳。

問題在哪

規劃 / 評論 / 重新規劃這三類請求相同 prompt 重複付費，浪費 30-60% AI 成本。

要改什麼

對 planner、critic、replan 入口預設打開快取；同時把 Anthropic prompt caching 自動套到 system prompt 尾部。

涉及檔案

server/_core/llm.ts:invokeLLM (line ~197-202 預設值 / ~1614 callEngine 注入 cache_control)

server/services/agentPlanner.ts (呼叫 invokeLLM 處)

shared/orb-plan-critic.ts (critic LLM 呼叫處)

server/services/orbLLMReplan.ts (replan 呼叫處)

server/services/ai-adapters/providers/anthropic.adapter.ts

Claude Code 提示詞 (複製貼上)

把下面這段話完整複製，貼到 Claude Code (或 /claude 對話)。Claude Code 會依此完成此項修復。完成後跑下方驗證步驟確認。

請依照計畫附錄 A.5 實作 A-PO-4 / G-PO-2 LLM Cache 接通：

1. 確認 `server/_core/cache.ts:CacheService` 與 `server/_core/llm.ts:invokeLLM` 既有的 `cacheable / cacheTtlSeconds` 機制 (line 197-202 與 1534-1557) 正常運作。寫一條測試確認：連跑兩次相同 prompt，第二次 `latency < 50ms` 且 `metrics llm.cache.hit +1`。
2. 修改 `server/services/agentPlanner.ts`、`shared/orb-plan-critic.ts`、`server/services/orbLLMReplan.ts` 等所有呼叫 `invokeLLM` 的入口，加上 `cacheable: true` 與 `cacheTtlSeconds: 1800` (30 min)。
3. 修改 `server/_core/llm.ts` 在 `callEngine()` (line ~1614) 之前加入 Anthropic prompt caching 自動套用：
 - 新增 `enablePromptCache?: boolean` 參數，預設 `true`
 - `engine === "anthropic"` 且 `enablePromptCache !== false` 時，在 `systemPromptBlocks` 尾部 push {
`type: "text", text: SYSTEM_FRAGMENT_END_MARKER, cache_control: { type: "ephemeral" } }`
 - Gemini 同樣支援 (依 SDK 欄位)
4. emit metrics : `llm.cache.hit / llm.cache.miss / llm.prompt_cache.creation_tokens / llm.prompt_cache.read_tokens`。
5. 跑既有的 `server/_core/llm-cache-dedupe.test.ts` 確認無回歸。

不要做的事：不要新增 Redis (屬於第 30 條未來擴張)。不要動 `buildLlmKey()` 的 hash 演算法。不要對 streaming 呼叫加 cache (streaming response 不適合 cache)。

如何驗證做完了

連跑兩次相同 planner prompt → 第二次 < 50ms 完成。檢查 Anthropic API response headers 看到 `cache_creation_input_tokens / cache_read_input_tokens > 0`。檢查 metrics dashboard `llm.cache.hit` 比率上升。

預估耗時

1-2 天