

#12 · 成本告警

[修復] 技術代號 O-PO-2 · 約 1 天

一句話：成本超標沒人通知

為什麼要修

每天 / 每小時花了多少錢只能等月底報表才看到。

現在怎樣

server/jobs/apiUsageAlertJob.ts 有月度預算告警但無 hourly threshold。閾值 hardcoded 在 line 67：monthlyBudget = Number(serverEnv.AI_MONTHLY_BUDGET_USD || 500)。

問題在哪

被攻擊狂打 API、模型定價突然上漲、cron

失控導致狂跑、使用者帳號被盜用大量呼叫都要月底才發現。

要改什麼

新增 hourly / daily threshold + Discord 告警 channel (既有 Discord webhook 在 apiHealthMonitor.ts 已用)。

涉及檔案

server/jobs/apiUsageAlertJob.ts (fireAlert 加 Discord 分支、新增 checkHourlyAlerts)

server/_core/notification.ts (新增 sendDiscordAlert)

server/_core/env.validated.ts (新增 env vars)

Claude Code 提示詞 (複製貼上)

把下面這段話完整複製，貼到 Claude Code (或 /claude 對話)。Claude Code 會依此完成此項修復。完成後跑下方驗證步驟確認。

請依照計畫附錄 A.8 實作 O-PO-2 即時成本告警：

1. 在 `server/_core/env.validated.ts` 新增四個 env vars :
 - `ALERT_DISCORD_WEBHOOK` (主用, 可從 `apiHealthMonitor.ts` 借用同一個)
 - `ALERT_SLACK_WEBHOOK` (保留既有)
 - `COST_ALERT_DAILY_USD` (預設 50)
 - `COST_ALERT_HOURLY_USD` (預設 20)
2. 在 `server/_core/notification.ts` 新增 `sendDiscordAlert(message, severity: "info"|"warn"|"crit")` :
 - 用 `fetch POST` 到 `ALERT_DISCORD_WEBHOOK`
 - 用 Discord embed 結構, `severity` 對應 embed color (info=藍、warn=黃、crit=紅)
 - 加 `timeout 5s + try-catch logger.warn`
3. 修改 `server/jobs/apiUsageAlertJob.ts` :
 - 把現有 `fireAlert(key, message)` 加第三參數 `severity`, 內部同時呼叫 `sendSlackAlert` (既有) 與 `sendDiscordAlert` (新增)
 - 新增 `async checkHourlyAlerts()` 函式: `getHourlySpend()` → 若 `> COST_ALERT_HOURLY_USD` 則 `fireAlert(`hourly_${new Date().toISOString().slice(0,13)}`, msg, "crit")`
 - 同樣新增 `checkDailyAlerts()`
 - 在 main job runner 內加上這兩個 check 的呼叫
4. 把 cron 頻率從 15 min 改成 5 min (cron 表達式 `"*/5 * * * *`) , 讓 hourly 偵測更靈敏。
5. 確認 `shouldAlert(key)` 的 1 小時 dedup 邏輯對 `hourly_xxx` key 仍正常 (`slice(0,13)` 拿小時級 key 確保同一小時內不重複) 。
6. 寫 vitest 測試: mock 過去一小時 `spend = $25` → 應觸發告警; `spend = $5` → 不觸發。

不要做的事: 不要在這條任務做「使用量 dashboard UI」(屬第 20 條)。不要為了告警阻擋業務流程(告警只是通知)。不要把預算改成硬上限(`cost guard` 第 18 條才處理上限)。

如何驗證做完了

模擬一小時內跑 30 條 Sora 影片 (會破 \$20 / hr) → Discord channel 應收到紅色 embed 告警, 內容含時間、金額、超出閾值。1 小時內不重複。

預估耗時

1 天