

#18 · 成本接通

[優化] 技術代號 A-P1-6 · 約 2-3 天

一句話：預估費用顯示不準

為什麼要修

「執行前預估費用」卡片用粗略估算。

現在怎樣

server/services/modelPricing.ts 是 3500 行完整 catalog (5 級 tier、basePoints + 超量加乘)、estimatePoints() / getModelPricing() 都已寫好，但 server/services/orbCostGuard.ts 用 tier-based heuristic 沒查它。

問題在哪

使用者看到的預估費用與實際差很多，無法做明智決定。

要改什麼

把 cost guard 接到 modelPricing catalog；plan-time 預估卡片改顯示真實 points + USD breakdown；對 catalog 加 30 min cache。

涉及檔案

server/services/orbCostGuard.ts (接通 modelPricing)

client/src/components/PlanApprovalCard.tsx (新增或重構，顯示真實成本)

server/services/modelPricing.ts (既有，不改)

Claude Code 提示詞 (複製貼上)

把下面這段話完整複製，貼到 Claude Code (或 /claude 對話)。Claude Code 會依此完成此項修復。完成後跑下方驗證步驟確認。

請依照計畫附錄 B.4 實作 A-P1-6 Cost catalog 接線：

【第 1 部分：cost guard 接通】

1. 在 server/services/orbCostGuard.ts 新增 helper：

```
```typescript
export async function enrichCostEstimateWithPricing(
 estimate: OrbCostEstimate,
 stepTools: string[],
): Promise<OrbCostEstimate & { totalPoints: number; breakdown: string }> {
 const { estimatePoints, getModelPricing } = await import("./modelPricing");
 let totalPoints = 0;
 const breakdown: string[] = [];
 for (const toolName of stepTools) {
 const modelId = getUserSelectedModel(toolName);
 const pricing = getModelPricing(modelId);
 if (pricing) {
 const points = estimatePoints({
 modelId,
 durationSec: estimate.estimatedDurationSec,
 charCount: estimate.estimatedCharCount,
 imageCount: estimate.estimatedAssetCount,
 });
 totalPoints += points.totalPoints;
 breakdown.push(`${toolName}=${points.totalPoints}pts`);
 }
 }
 return { ...estimate, totalPoints, breakdown: breakdown.join(" + ") };
}
```
```

【第 2 部分：catalog cache】

2. 新增 catalog cache (30 min TTL)：

```
```typescript
const PRICING_CACHE_TTL_MS = 30 * 60 * 1000;
let cachedCatalog: typeof MODEL_PRICING_CATALOG | null = null;
let cachedAt = 0;
```

```

export async function getPricingCatalogCached() {
 if (cachedCatalog && Date.now() - cachedAt < PRICING_CACHE_TTL_MS) return cachedCatalog;
 const { MODEL_PRICING_CATALOG } = await import("./modelPricing");
 cachedCatalog = MODEL_PRICING_CATALOG;
 cachedAt = Date.now();
 return cachedCatalog;
}
...

```

### 【第 3 部分：approval card UI】

3. 新增（或重構既有 CostGateCard）client/src/components/PlanApprovalCard.tsx：

```

````tsx
export interface PlanApprovalCardProps {
  taskId: string;
  steps: AgentPlanStep[];
  costEstimate: { totalPoints: number; breakdown: string; tier:
    "free"|"economy"|"standard"|"premium"|"ultra" };
  userBudget?: number;
  onApprove: () => void;
  onCancel: () => void;
}

export function PlanApprovalCard(props) {
  const pointsToUsd = (pts: number) => `$$${(pts / 100).toFixed(2)}`;
  const budgetRemaining = props.userBudget ? props.userBudget - props.costEstimate.totalPoints :
    null;
  // 顯示：N 步驟分解 + 每步 points + 合計（pts + USD）+ 預算徽章 + tier badge + 詳細 breakdown
  details
  // ...
}
...

```

4. 在 server/services/orbTaskOrchestrator.ts 或 planner，把 plan 編譯後呼叫
enrichCostEstimateWithPricing()，把結果塞入 plan metadata，前端 approval card 接收顯示。

5. 整合到既有 ProactiveOrbWidget 的 approval flow（重用 PlanApprovalCard，刪除舊版內嵌版本）。

不要做的事：不要動 modelPricing.ts catalog 本身（既有 3500 行 SSOT）。不要把 cost guard
改成硬阻擋（保留 cost-aware 但讓使用者決定）。不要顯示細部 USD
計算公式給使用者（複雜、容易誤導，只顯示總金額）。

如何驗證做完了

在 ImageStudio 用 kling-v2-pro 跑 5s 影片 → approval card 顯示「30 pt = \$0.30」（真實定價，非粗估）。詳細 breakdown 點開看到 kling-v2-pro=30pts。修改 modelPricing.ts 內某個價格 → 30 分鐘內 catalog 自動刷新。

預估耗時

2-3 天