

#26 · 語音進階

[新增] 技術代號 VA-P1 / VA-P2 部分 · 約 10-15 天

一句話：語音對話進階體驗（階段 B / C）

為什麼要修

MVP（第 5 條）完成後，使用者體驗自然度仍不及 ChatGPT Advanced Voice / Gemini Live。

現在怎樣

MVP 須按住麥克風講話、機器在說時不能打斷、跨會話不記得上次說過什麼、混語對話 TTS 不會切引擎。

問題在哪

對話不夠自然，使用者用一次就覺得「還是要打字」。

要改什麼

三件事（分階段）：(B) VAD 自動偵測說完 + barge-in 中斷 + 多輪會話記憶；(C) 中英混語自動切 TTS、Wake word「嘿暖暖」、個人聲線預設。階段 C 可砍。

涉及檔案

client/src/hooks/useSileroVad.ts（新增）

server/voice/voiceStreamingTranscriber.ts（新增）

server/voice/voiceInterruptionHandler.ts（新增）

server/voice/voiceHistoryManager.ts（新增）

client/src/hooks/useWakeWord.ts（新增，C 階段）

server/voice/voiceMultimodalIntake.ts（新增）

Claude Code 提示詞 (複製貼上)

把下面這段話完整複製，貼到 Claude Code (或 /claude 對話)。Claude Code 會依此完成此項修復。完成後跑下方驗證步驟確認。

請依照計畫附錄 E.6 / E.7 / E.8 / E.10 / E.12 / E.13 實作 VA-P1 / VA-P2 語音進階：

前置：第 5 條 (語音 MVP) 必須先完成。

【階段 B (建議做)】

【B-1：STT streaming + 語意 VAD (VA-P1-1)】

1. 新增 server/voice/voiceStreamingTranscriber.ts，匯出 createTranscriber(provider: "gemini-live" | "elevenlabs-realtime"): StreamingTranscriber 介面，含 feedAudio / flush / onPartial / onFinal / cancel 方法。

- Gemini Live：用 @google/genai 的 live.connect() API

- ElevenLabs：WebSocket 連 wss://api.elevenlabs.io/v1/speech-to-text/stream

2. 在 voiceAgentSession 改為串流模式 (不是按完一次才轉錄)。

3. 新增 client/src/hooks/useSileroVad.ts，用 @ricky0123/vad-web (Silero WebAssembly)：偵測 800ms 靜音 → 觸發 end-utterance；偵測說話開始 → emit speech-start (給 barge-in 用)。

```
````typescript
export function useSileroVad(stream: MediaStream | null, onSpeechEnd: () => void) {
 useEffect(() => {
 if (!stream) return;
 let vad: any;
 (async () => {
 const { MicVAD } = await import("@ricky0123/vad-web");
 vad = await MicVAD.new({
 stream,
 positiveSpeechThreshold: 0.8,
 negativeSpeechThreshold: 0.35,
 minSpeechFrames: 5,
 redemptionFrames: 12,
 onSpeechEnd,
 });
 vad.start();
 })();
 return () => vad?.destroy();
 }, [stream, onSpeechEnd]);
}
````
```

【B-2 : Barge-in (VA-P1-2)】

4. 新增 server/voice/voiceInterruptHandler.ts，維護 Map<orbTraceId, AbortController>，cancel() 觸發所有 in-flight abort (包含 TTS stream、tool execution)。
5. 前端 useOrbVoice 在收到 speech-start 時 emit {type: "interrupt"} 給 WebSocket、同時呼叫 useAudioPlayback.cancel() 清空播放佇列。
6. 確認 MediaRecorder constraints echoCancellation: true (防止機器自己 TTS 觸發 VAD)。

【B-3 : 多輪會話記憶 (VA-P1-3)】

7. 新增 server/voice/voiceHistoryManager.ts：每個 voice turn 寫入既有 orbConversations + orbConversationMessages 表 (含 mediaType: "voice"、audioUrl)。
8. 下次 dispatch 前撈最近 10 條 messages 注入 planner system prompt：

```
```typescript
```

```
const memory = await voiceHistoryManager.getRecentTurns(session.userId, session.orbTraceId, 10);
const memorySummary = memory.map((t) => `${t.role}: ${t.text}`).join("\n");
plannerSystemPrompt += `\n\n# 本次語音會話歷史\n${memorySummary}`;
```
```

【B-4 : 多語言混語 TTS 自動切 (VA-P1-5)】

9. 在 voiceAgentOrchestrator 增加 splitByLanguage(text) 把 TTS 回應依語言分段。
10. 每段用既有 voiceSpecialistTools:pickTtsEngine(lang) 選引擎：zh/ja/ko → Qwen、en/es/fr/de → ElevenLabs V3、其他 → ElevenLabs Multilingual V2。
11. server 端依序 stream 多 TTS engine 結果到同 WebSocket。

【階段 C (可選做，時程吃緊可砍)】

【C-1 : Wake word (VA-P2-1)】

12. 新增 client/src/hooks/useWakeWord.ts，用 @picovoice/porcupine-web：
 - 本地 WebAssembly 偵測「嘿暖暖」（在 Picovoice Console 訓練）
 - 預設關閉，Settings 必須使用者明確開啟
 - 偵測完全本地、不傳音訊到 server
 - 喚醒後顯示「暖暖在聽…」3 秒無人聲自動關閉

【C-2 : 個人聲線預設 (VA-P2-2)】

13. 在 agentPreferences 新增 voicePreferences: { defaultAssistantVoicelId?: string; defaultLanguageVoiceMap?: Record<string, string>; }
14. 使用者首次訓練聲線完成 → toast「要把暖暖的聲音換成你自己的嗎？」
15. 接受 → 寫 defaultAssistantVoicelId、之後 voiceAgentOrchestrator 用此 voicelId。

不要做的事：不要做 emotion-adaptive TTS (屬季度級工程)。不要做 voice-only Studio 完整模式 (依賴 V-P2 全套未做)。不要做離線本地 fallback。

如何驗證做完了

階段 B：使用者不用按按鈕，說完 800ms 自動觸發轉錄。機器在說的時候開口立即停（< 200ms）。下次連線記得「上次說的森林風」。中英混語自動切引擎、無不自然停頓。階段 C：「嘿暖暖」喚醒可用、個人聲線可設為預設。

預估耗時

10-15 天