

#34 · Replicate 備援

[未來] 技術代號 G-P1-3 · 約 3-4 週

一句話：開第二家供應商備援

為什麼要修

Replicate 在你的網站只用了 LoRA 訓練。

現在怎樣

server/services/loraTrainer.ts 只整合 Replicate 訓練端點。FAL 主力故障時無備援。

問題在哪

FAL 偶爾當機（5% 機率），使用者看到「生成失敗」。

要改什麼

把 Replicate 的圖 / 影 / 3D 也接進來、與 unifiedModelRegistry 的 fallbackChain 整合（cross-provider fallback）。

涉及檔案

server/services/replicateClient.ts（新增，仿 sunoClient 結構）

server/services/falModels.ts（disabled 模型加 replacement: replicate/xxx）

shared/unifiedModelRegistry.ts（fallbackChain 加 Replicate 條目）

server/services/falDispatcher.ts（dispatchWithFallback 串 Replicate）

Claude Code 提示詞 (複製貼上)

把下面這段話完整複製，貼到 Claude Code (或 /claude 對話)。Claude Code 會依此完成此項修復。完成後跑下方驗證步驟確認。

請依照計畫附錄 C.3 / C.4 實作 G-P1-3 Replicate 模態擴張：

3-4 週工程，分階段。

【Phase 1 : text-to-image (最高優先)】

1. 新增 server/services/replicateClient.ts，仿 server/services/loraTrainer.ts 既有的 Replicate 用法：

```
```typescript
export class ReplicateClient {
 async runModel(modelId: string, input: Record<string, unknown>, opts?: { webhookUrl?: string }) {
 // 用 replicate.run() 或 replicate.predictions.create()
 // 支援同步 + 非同步 (webhook callback)
 }
 async checkStatus(predictionId: string) { ... }
}
```
```

2. 接入這些 Replicate 模型作為 FAL Flux 的備援：

- replicate/black-forest-labs/flux-1.1-pro
- replicate/black-forest-labs/flux-dev
- replicate/black-forest-labs/flux-schnell

3. 修改 shared/unifiedModelRegistry.ts 加 fallbackChain：

```
```typescript
"fal-ai/flux-pro/v1.1": {
 ...,
 fallbackChain: ["replicate/black-forest-labs/flux-1.1-pro", "gemini/imagen-4"],
}
```
```

4. 修改 server/services/falDispatcher.ts:dispatchWithFallback：依 chain 逐家試，遇 429 / 5xx / 超時降級下一家。

【Phase 2 : image-to-video (3 週後)】

5. 接 replicate/luma/ray-2、replicate/genmo/mochi-1 作為 fal kling 的備援。

6. 更新 fallbackChain :

```
```typescript
"fal-ai/kling-v2-pro": {
 fallbackChain: ["replicate/luma/ray-2", "replicate/genmo/mochi-1"],
}
```
```

【Phase 3 : video-to-video / 3D (時程吃緊可砍)】

7. 接 replicate/cjwbw/kling-v2v 等 v2v 模型。

8. 接 replicate/lucataco/hunyuan3d-v2 等 3D 模型。

【共用 : dispatcher 改造】

9. 修改 dispatchWithFallback 統一抽象 (之前在計畫附錄 C.3.2) :

```
```typescript
async function dispatchWithFallback(modelId: string, category: FalCategory, inputs):
Promise<DispatchResult> {
 const chain = [modelId, ...(getModelById(modelId)?.fallbackChain ?? [])];
 for (const [i, id] of chain.entries()) {
 try { return await callModelByProvider(id, category, inputs); }
 catch (err) {
 if (i === chain.length - 1) throw err;
 logger.warn("fallback_attempt", { from: id, to: chain[i + 1], err });
 }
 }
}
```
```

callModelByProvider 依 modelId prefix 路由 : fal-ai/... → falDispatcher、replicate/... → replicateClient、gemini/... → geminiMedia。

不要做的事 : 不要把所有 fal 模型都接 Replicate 對應品 (只接主力模型)。不要做「主動 health check 切換」 (被動 fallback 即可)。不要做使用者可選「我要用 Replicate」 (透明降級)。

如何驗證做完了

故意把 fal-ai/flux-pro/v1.1 設成不可用 (mock 5xx) → 生圖請求自動切到 replicate flux-1.1-pro → 使用者不感知任何錯誤、只是 latency 多 2-3 秒。log 看到 fallback_attempt: fal-ai/flux-pro →

replicate/flux-1.1-pro。

預估耗時

3-4 週