

全站費用盤點 與成本深度研究

API 生成 · 基礎設施 · 營運 · 計費機制 · 你沒想到的隱藏成本

專案：healing-studio (AI Director / director.today)。本報告兩路資料交叉：①repo 內成本碼 (server/services/modelPricing.ts 200 條模型定價、cost_ledger 帳本、currency.ts 匯率、.env.example 服務清單)；②2026-06 對各供應商官網/定價頁的網路實價研究 (逐項附來源)。所有金額以 USD 計，內部積分 1 USD=100 pts，報表 USD->TWD 預設匯率 31.5 (currency.ts，可由 USD_TO_TWD_RATE 覆寫)。

重要：本報告為成本『結構與單價』盤點，非帳單對帳；實際月費取決於真實用量。標『待接/缺金鑰』者目前未產生費用。

1. 全站付費服務一覽（用途 · 計費模式 · 2026 現行價 · 狀態）

狀態：[有]=已接線生效 · [進行]=部分/旗標下 · [待]=規劃未接 · 缺金鑰=程式已備、未貼金鑰故不計費。

服務	用途	計費模式 / 2026 現行價	狀態	來源
Railway	主機/部署 (compute+RAM+egress+volume)	用量：\$20/vCPU·月、\$10/GB RAM·月、egress \$0.05/GB、磁碟 \$0.15/GB·月；Pro \$20/席含\$20	[有]	railway.com/pricing
Cloudflare R2	媒體/上傳/DB 備份 物件儲存	儲存 \$0.015/GB·月、egress \$0 (免費)、Class A \$4.50/百萬、Class B \$0.36/百萬；免費 10GB	[有]	developers.cloudflare.com/r2/pricing
MySQL (DATABASE_URL)	主資料庫 (87 表)	依供應商 (PlanetScale/CloudSQL)；用量或固定方案	[有]	-
Redis (Railway)	生成防重複鎖 (AIDV-20) / 未來快取	Railway Redis 服務 = 另計 compute+RAM (小型約 \$5-10/月)	缺金鑰	railway.com
OpenRouter	統一 LLM 閘道 (主路由)	購點 +5.5% 手續費；每 token 與直連同價	[有]	openrouter.ai
Anthropic Claude	光球/代理主引擎 (直連選用)	Haiku4.5 \$1/\$5、Sonnet4.6 \$3/\$15、Opus4.8 \$5/\$25 (每百萬 in/out)；快取-90%、批次-50%	[有]	platform.claude.com/docs/pricing
Google Gemini/Vertex	LLM + Imagen 圖像 + Veo 影片	Imagen3 ~\$0.04/張、Veo2 ~\$0.35/5s (catalog 參考)；Vertex 另計	[有]	-
fal.ai	主力生成 (圖/影/音/3D/訓練) 151 模型	逐模型計：圖 \$0.003-0.06、影片 \$0.10-0.80、訓練 \$1-5/次	缺金鑰	fal.ai (帳號頁為準)
Replicate	LoRA 訓練備援	逐模型/秒計 (需 REPLICATE_API_TOKEN)	缺金鑰	replicate.com
ElevenLabs	語音/配音	API Pro \$99/月、Scale \$330/月；~1 credit/字元 (Flash/Turbo 0.5)	缺金鑰	elevenlabs.io/pricing/api
Suno	配樂 (無官方 API)	官方訂閱制；第三方轉售 \$0.014-0.111/首	缺金鑰	suno.com/pricing
Perplexity Sonar	聯網研究 (real-earth/news/learn)	Sonar \$1/\$1、Sonar Pro \$3/\$15 (每百萬) + 每千次請求 \$5-14 (依 context)	[進行]	docs.perplexity.ai pricing
Pinecone	向量記憶 RAG (現用)	儲存 ~\$0.33/GB·月、讀 \$8.25/百萬RU、寫 \$2/百萬WU；Standard 月最低 \$50；免費 2GB	[有]	pinecone.io/pricing
Supabase	規劃遷移目標 (pg+pgvector)	Pro \$25/月含 250GB egress；egress \$0.09/GB (快取 \$0.03)	[待]	supabase.com/pricing
Stripe	金流/儲值 (webhook 已備)	標準 2.9% + \$0.30/筆 (台灣費率以帳號為準)	[進行]	stripe.com/pricing
Sentry	錯誤/效能監控 (取樣 10%)	Dev 免費 / Team 約 \$26/月起 (依事件量)	選用	sentry.io/pricing
網域 director.today	.today TLD 年費	約 \$20-30/年	[有]	-
Forge (maps proxy)	地圖/butterfly-effect 代理	依方案 (外部)	[進行]	forge.butterfly-effect.dev
Email 寄送	驗證/重設密碼信 (schema 有 token 表)	未見 Resend/SES/SMTP 金鑰 = 寄送供應商尚未設定 (潛在缺口)	缺金鑰	-

2. API 生成成本 - 依類別 (repo modelPricing.ts 實價，200 模型)

每類列：模型數、真實 USD 成本區間、中位數、平台積分 (basePoints=baseCostUsdx100)。影片與訓練最貴；免費/便宜模型多為 fal flux-schnell (\$0.003) 等。所有單價以 fal/各家『帳號頁』為最終準。

類別	模型數	USD 成本區間 (每次)	中位數	中位積分
模型訓練/LoRA	8	\$1.000–\$5.000	\$2.500	250 pts
文字生影片	21	\$0.150–\$0.800	\$0.300	30 pts
圖生影片	21	\$0.100–\$0.550	\$0.200	20 pts
影片轉影片	14	\$0.080–\$0.450	\$0.165	16 pts
文字生 3D	5	\$0.050–\$0.200	\$0.120	12 pts
影片配音	2	\$0.080–\$0.150	\$0.115	12 pts
音樂/音效	21	\$0.010–\$0.100	\$0.050	5 pts
圖生 3D	9	\$0.040–\$0.120	\$0.050	5 pts
推理模型	23	\$0.003–\$0.120	\$0.040	4 pts
文字生圖	19	\$0.003–\$0.060	\$0.020	2 pts
圖生圖/控制	17	\$0.001–\$0.050	\$0.020	2 pts
語音合成 TTS	22	\$0.005–\$0.080	\$0.020	2 pts
LLM 文字	11	\$0.005–\$0.050	\$0.020	2 pts
語音轉文字	1	\$0.020–\$0.020	\$0.020	2 pts
圖像理解	4	\$0.005–\$0.020	\$0.013	1 pts
影片轉文字	2	\$0.004–\$0.006	\$0.005	0 pts

最貴類別：文字生影片 (\$0.15–0.80/支)、圖生影片 (\$0.10–0.55)、模型訓練 (\$1–5/次)。這三類是燒錢主力--一支 8 秒精修影片可能 \$0.5–0.8，等於 50–80 積分；訓練一顆 LoRA 等於 100–500 積分。

3. 基礎設施 / 營運固定成本（每月估算）

與用量較無關、近似固定的月度開銷。數字為『典型小型正式站』量級的估算區間，非帳單。

項目	說明	月估	備註
Railway 主容器	1 vCPU + 1 GB RAM 24/7 (含多支 cron 無法縮到零)	\$30/月 (\$20 CPU+\$10 RAM)	cron : dbSnapshot/outbox/reconcile/autoCredit/r2Snapshot 讓容器常駐
Railway Pro 訂閱	每席 \$20/月 (含 \$20 用量額度)	\$20/月	團隊席位另計
Railway egress	出站流量 \$0.05/GB	用量；媒體走 R2 直傳可避免	AIDV-15 signed-URL 直傳 R2 = 省這條
Redis 服務	Railway Redis (小型)	\$5-10/月	AIDV-20；缺金鑰時不計
MySQL 資料庫	託管 MySQL (PlanetScale/CloudSQL 等)	\$0-29/月起	依供應商方案
Cloudflare R2 儲存	媒體 + 每日 DB 備份累積	\$0.015/GB·月 (前 10GB 免費)	備份每日 PutObject = Class A，需 TTL 控制
Pinecone 向量庫	RAG 記憶 (halfvec 3072 維，單筆~6KB)	Standard 月最低 \$50	遷 Supabase pgvector 後可降為 \$0 (含在 Pro)
Supabase (遷移後)	pg + pgvector 取代 MySQL+Pinecone	Pro \$25/月 (含 250GB egress)	遷移期間可能 MySQL+Supabase 並存 = 暫時雙倍
Sentry 監控	錯誤/效能 (取樣 10%)	\$0-26/月	選用；事件量大才升級
網域	director.today 年費	~\$2/月 (\$20-30/年)	-

固定基線概估：Railway ~\$50 (容器+訂閱+Redis) + Pinecone \$50 (或遷 Supabase 後 \$25) + DB \$0-29 + 網域 \$2 + 監控 \$0-26 ~ 每月 \$100-160 的『不生成也要付』底盤；其上才是隨用量浮動的 API 生成費。

4. 計費 / 積分機制與內部經濟 (repo 實證)

機制	規則 (原碼)	影響/備註
積分匯率	1 USD = 100 pts (shared/currency.ts POINTS_PER_USD)	使用者看 pts，後台換算 USD/TWD
USD->TWD	預設 31.5 (DEFAULT_USD_TO_TWD_RATE, 可由 USD_TO_TWD_RATE 覆寫)	落帳當下凍結匯率 (AIDV-14) + 稽核欄
新用戶免費額度	remainingGenerations 預設 50 (schema users)	= 直接補貼：50 次生成成本由平台吸收
自動補點	autoCreditAmount 預設 0 / 每 7 天 (預設關)	開啟 = 週期性免費補貼 (userAutoCreditJob cron)
計費公式	basePoints + 時長x秒費 + 字數x千字費 + 張數x張費 + 訓練步數x步費, clamp[min,max]	modelPricing.ts estimatePoints
成本落帳	真實 costUsd (非估算) ->cost_ledger; 多維歸屬 member/project/workflow	AIDV-14; outbox 不漏帳 + 彙總淨額
失敗全退	估->原子扣->失敗全額退點 (AIDV-160 成本同意守門)	注意：供應商可能仍對失敗/部分生成收費 = 平台淨損
免費引擎紅線	選免費引擎絕不無聲回退付費並扣點 (AIDV-160)	創作者紅線：不偷扣

免費額度的真實補貼成本：50 次若都是 flux-pro 圖 (\$0.04) = \$2/人；若含影片 (\$0.3–0.8/支) 可達 \$15–40/人。新用戶湧入或濫用 (多帳號) 會直接放大這筆補貼--這是最容易被低估的成本。

5. 你可能沒想到的隱藏 / 易漏成本（重點）

以下每一項都對應 repo 內真實機制或本研究查到的計價細節，最容易在估算時被漏掉：

項目	為什麼會漏 / 機制	對策 / repo 對應
失敗仍付費	失敗/部分生成平台對使用者全額退點，但供應商常已對該次 API 收費 -> 淨損漏帳	落帳記 costUsd；建議追蹤「退點但已付費」差額
LLM 重試疊加	classifyLLMError 把暫時錯誤判 transient->重試，一次邏輯請求 = 多次付費 token	AIDV-165 invalid_model 曾誤重試燒錢；已修為 permanent_model 不重試
Perplexity 請求費	每千次請求 \$5-14（依 context 大小）是在 token 費『之上』，極易漏算	research/news/learn/real-earth 多處呼叫 = 請求費累積
OpenRouter 5.5%	走統一閘道方便，但每筆比直連 Anthropic 貴 5.5%	\$1000/月 LLM = 多付 \$55/月
多代理 token 乘數	光球 + 25 精靈 + global agent 編排，每回合都是 token；多代理 = 成倍 token	orchestrator/critic/verifier 各自呼叫 LLM
Pinecone 月最低	Standard 即使幾乎沒用也月付 \$50 門檻	這正是 AIDV-18 遷 Supabase pgvector 想省掉的
向量維度成本	halfvec(3072) 單筆~6KB，記憶/RAG 條目越多儲存越貴	HNSW 索引另佔空間
R2 操作費	egress 免費，但 PutObject/上傳=Class A(\$4.50/百萬)、magic-byte GetObject=Class B	AIDV-64 每次上傳多一次 Range GetObject
DB 備份累積	每日 mysqldump->R2，無 TTL 會無限長大->儲存費爬升	建議 lifecycle 保留 N 天
容器無法縮零	多支 cron（備份/對帳/補點/快照）讓 Railway 容器 24/7 常駐，付滿月	compute 是固定底盤
Railway 記憶體尖峰	上傳走 base64-over-tRPC 會吃 RAM（\$10/GB·月）	AIDV-15 signed-URL 直傳 = 省 RAM 與 egress
FX 匯率風險	成本記 USD、報表/收費換 TWD，匯率波動侵蝕毛利	cost_ledger 凍結匯率僅供對帳，不對沖風險
Stripe 固定費	每筆 +\$0.30；小額儲值被 \$0.30 吃掉比例高	鼓勵較大額儲值包
訓練最貴	LoRA 訓練 \$1-5/次（pointsPerStepx步數），少量用戶就拉高帳單	fal/replicate；缺金鎰時未啟用
遷移期雙跑	MySQL->Supabase 切換期間兩庫並存 = 暫時雙倍 DB 費	規劃排在任務耐久化之後
免費額度濫用	50 免費生成x多帳號 = 補貼放大；無防濫用 = 成本破口	建議裝置/IP/驗證門檻
Sentry 取樣量	traces 取樣 10%，流量大時事件量->升級方案	SENTRY_TRACES_SAMPLE_RATE 可調
Webhook 重試	fal webhook+polling 雙路徑，若不冪等可能重複觸發下游/重複計費	已用唯一鍵/idempotency 守門（AIDV-158/163）

6. 成本優化建議（多數已在卡上）

手段	效益	狀態 / 卡
Cloudflare AI Gateway	免費快取/觀測 LLM 回應，重複問答直接命中快取省 token	AIDV-11 已接 (CF_AI_GATEWAY_*)
Prompt caching	Claude 快取輸入 -90%；系統提示/精靈人格固定段落最適合	目前未明確啟用 = 可省
Batch 批次	Claude 批次 -50%；非即時任務（補登記/分析）可走	可評估
signed-URL 直傳	大檔不過 Node = 省 Railway RAM + egress + 不重複儲存	AIDV-15 已上（預設 ON 可回退）
遷 Supabase 退役 Pinecone	pgvector 併入 Pro \$25，省 Pinecone \$50 月最低	AIDV-18（缺金鑰，排耐久化後）
免費引擎優先	遊樂場/試生成優先 flux-schnell(\$0.003)/imagen-fast(\$0.01)	registry 已分 tier
R2 lifecycle	DB 備份/暫存設 TTL，避免儲存無限長	建議補 lifecycle rule
成本同意守門	高價生成前先估 + 確認門，避免誤觸貴模型	AIDV-160 成本常駐儀表
免費額度防濫用	Email 驗證 + 裝置/IP 限制，降低多帳號補貼破口	emailVerified 已有，可加限制

7. 範例每月帳單情境（量級概估，非報價）

假設：固定底盤 = Railway \$50 + Pinecone \$50 + DB \$10 + 網域/監控 \$5 ~ \$115/月。其上隨用量：

情境	主要組成	月費量級
啟動期（缺生成金鑰）	底盤 \$115；LLM 少量（OpenRouter）\$5–20；無圖/影/音生成	約 \$120–135/月
小量上線（100 活躍用戶）	底盤 \$115 + 圖像 \$20–60 + 少量影片 \$30–120 + LLM/研究 \$20–60	約 \$185–355/月
成長期（1000 用戶·含影片）	底盤 \$140（升配）+ 影片為主 \$300–1200 + LLM/研究 \$100–300 + 語音/音樂 \$50–200	約 \$590–1840/月

結論：①不生成也有約 \$115/月底盤（Railway+Pinecone 為大宗，遷 Supabase 可砍 Pinecone）；②一旦開影片生成，單項就可能蓋過所有基礎設施-影片是頭號成本中心，務必前置成本確認門；③免費 50 額度 + 自動補點是隱性補貼，規模化前要先設防濫用與儲值轉換。